

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG

KHOA CÔNG NGHỆ THÔNG TIN

KHOÁ D23



BÁO CÁO THỰC TẬP CƠ SỞ

Đề Tài: Xây Dựng Hệ Thống Nhận Diện Cảm Xúc

Con Người

NHÓM LỚP: 11

Giáo Viên Hướng Dẫn: Kim Ngọc Bách

Sinh viên thực hiện

Nguyễn Ngọc Bảo MSV: B23DCCN077

Hà Nội – 2026

LỜI CẢM ƠN

"Lời đầu tiên, em xin gửi lời cảm ơn chân thành đến Học viện Công nghệ Bưu chính Viễn thông đã tạo điều kiện để chúng em tiếp cận môn học Thực tập cơ sở — một học phần quan trọng giúp kết nối lý thuyết và thực hành, môn học là hành trang quan trọng để chúng em hiểu rõ hơn về ngành học cũng như những công việc sẽ phải làm sau này.

Em đặc biệt bày tỏ lòng biết ơn tới **thầy Kim Ngọc Bách**. Dù mới ở giai đoạn định hướng đề tài, thầy đã tận tình dẫn dắt và giải đáp các câu hỏi, giúp chúng em định hình ý tưởng và phương pháp tiếp cận đúng đắn. Những kinh nghiệm quý báu của thầy sẽ là cơ sở để em xây dựng một đề tài nghiêm túc và khoa học.

Do bước đầu làm quen với nghiên cứu và thực tiễn, cũng như lần đầu thử sức ở lĩnh vực liên quan đến AI, đề tài chắc chắn không tránh khỏi những thiếu sót. Em rất mong nhận được sự góp ý của thầy để em có thể hoàn thiện project một cách hiệu quả và rút ra được nhiều kinh nghiệm trên lĩnh vực chinh phục AI của mình”

Hà Nội, Tháng 6 năm 2026

Sinh Viên

Nguyễn Ngọc Bảo

Contents

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI	6
1.1 Bối cảnh và tính cấp thiết của đề tài.	6
1.2. Mục đích nghiên cứu.	7
1.3. Đối tượng và phạm vi nghiên cứu.	8
1.3.1. Đối tượng nghiên cứu	8
1.3.2. Phạm vi nghiên cứu	9
1.4. Phương pháp tiếp cận và Định hướng giải pháp	9
1.4.1. Phương pháp tiếp cận	9
1.4.2. Định hướng giải pháp	10
1.5. Ý nghĩa khoa học của đề tài	12
1.5.1. Ý nghĩa khoa học.....	12
1.5.2. Ý nghĩa thực tiễn	12
1.6 Bố cục báo cáo của bài tập lớn	13
CHƯƠNG 2 : CƠ SỞ LÝ THUYẾT VÀ CÔNG NGHỆ LIÊN QUAN	13
2.1 Tổng quan về nhận diện cảm xúc khuôn mặt	13
2.2 . Các trạng thái cảm xúc cơ bản.	14
2.3. Học máy, học sâu.	14
2.3.1 Tổng quan về trí tuệ nhân tạo	14
2.3.2 Học máy (Machine Learning)	15
2.3.3. Học sâu (Deep Learning)	15
2.4 Mạng nơ-ron nhân tạo (neural networks)	17
2.5 Mạng nơ-ron tích chập (CNN)	18
2.5.1 Kiến trúc điển hình của một mạng CNN	18
2.5.2 Các thành phần cốt lõi của CNN	19
2.6 Kiến trúc ResNet50	25
2.6.1. Giới thiệu ResNet	25
2.6.2 Tại sao lại xuất hiện mạng ResNet	25

2.6.3 Kiến trúc mạng Resnet	26
2.7. Transfer Learning	28
2.8. Bộ dữ liệu RAF-DB	28
2.9 Các kỹ thuật xử lý dữ liệu	29
2.10 Các chỉ số đánh giá mô hình	29
2.10.1 Accuracy	29
2.10.2 Precision	29
2.10.3 Recall	30
2.10.4 F1-Score	30
2.10.5 Confusion Matrix	30
2.11 Công nghệ sử dụng trong đề tài	30
CHƯƠNG 3. PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG NHẬN DIỆN CẢM XÚC CON NGƯỜI	31
3.1. Quy trình tổng quan của hệ thống	31
3.2. Phân tích và chuẩn bị dữ liệu RAF-DB.....	33
3.2.1. Giới thiệu bộ dữ liệu RAF-DB	33
3.2.2. Cấu trúc dữ liệu	33
3.2.3. Chia tập dữ liệu	33
3.3. Tiền xử lý dữ liệu ảnh	34
3.3.1. Thay đổi kích thước ảnh	34
3.3.2. Chuyển đổi ảnh sang Tensor	34
3.3.3. Chuẩn hóa dữ liệu	34
3.4. Tăng cường dữ liệu (Data Augmentation)	34
3.4.1. Mục đích tăng cường dữ liệu	34
3.4.2. Các kỹ thuật tăng cường dữ liệu được sử dụng	35
3.5. Thiết kế kiến trúc mô hình ResNet50	35
3.5.1 Lựa chọn mô hình	35
3.5.2 Cấu trúc tổng thể của ResNet50	35
3.5.3. Residual Learning	36
3.5.4. Thiết kế lớp phân loại cảm xúc	36
3.6. Transfer Learning	36

3.6.1. Khái niệm Transfer Learning	36
3.6.2. Áp dụng Transfer Learning trong ResNet50	36
3.6.3. Lợi ích của Transfer Learning	37
3.7. Cấu hình huấn luyện mô hình	37
3.7.1. Hàm mất mát (Loss Function)	37
3.7.2. Thuật toán tối ưu	37
3.7.3. Điều chỉnh tốc độ học (Learning Rate Scheduling)	37
3.7.4. Dropout và Regularization	37
3.7.5. Các siêu tham số huấn luyện	38
3.8. Lưu trữ và tải mô hình	38
3.8.1. Cơ chế lưu checkpoint	38
3.8.2. Lưu mô hình tốt nhất	38
3.8.3. Khôi phục quá trình huấn luyện	38
3.9. Thiết kế giao diện hệ thống (Streamlit Interface)	38
CHƯƠNG 4. KẾT QUẢ THỰC NGHIỆM VÀ ĐÁNH GIÁ	40
4.1. Môi trường thực nghiệm	40
4.1.1. Cấu hình phần cứng	40
4.1.2. Cấu hình phần mềm.....	40
4.2. Dữ liệu thực nghiệm	40
4.3. Quá trình huấn luyện mô hình	41
4.4. Kết quả huấn luyện	41
4.5. Đánh giá trên tập kiểm thử	42
CHƯƠNG 5. KẾT LUẬN VÀ ĐỀ XUẤT HƯỚNG PHÁT TRIỂN	44
5.1. Kết luận	44
5.2. Hạn chế của hệ thống	44
5.3. Đề xuất hướng phát triển	45
Tài liệu tham khảo	46

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI

1.1 Bối cảnh và tính cấp thiết của đề tài.

Trong những năm gần đây, sự phát triển mạnh mẽ của Trí tuệ nhân tạo (AI) và Học sâu (Deep Learning) đã tạo ra nhiều bước tiến vượt bậc trong lĩnh vực Thị giác máy tính (Computer Vision). Một trong những bài toán nhận được nhiều sự quan tâm là nhận diện cảm xúc khuôn mặt (Facial Expression Recognition - FER), bởi cảm xúc đóng vai trò quan trọng trong giao tiếp và tương tác giữa con người với nhau cũng như giữa con người với máy tính .

Theo các nghiên cứu về giao tiếp phi ngôn ngữ, biểu cảm khuôn mặt là nguồn thông tin quan trọng giúp phản ánh trạng thái cảm xúc, tâm lý và hành vi của con người. Khả năng tự động nhận diện cảm xúc từ hình ảnh khuôn mặt giúp máy tính

hiểu được trạng thái của người dùng, từ đó nâng cao chất lượng tương tác và hỗ trợ ra quyết định trong nhiều lĩnh vực khác nhau.

Hiện nay, nhận diện cảm xúc khuôn mặt được ứng dụng rộng rãi trong nhiều hệ thống thực tế như: giáo dục thông minh, chăm sóc sức khỏe, hỗ trợ tâm lý, giám sát an ninh, đánh giá trải nghiệm khách hàng, robot giao tiếp và các hệ thống tương tác người – máy. Đặc biệt, trong bối cảnh chuyển đổi số và sự phát triển của các ứng dụng trực tuyến, nhu cầu xây dựng các hệ thống có khả năng hiểu và phản hồi theo cảm xúc của người dùng ngày càng trở nên cấp thiết.

Tuy nhiên, việc nhận diện cảm xúc khuôn mặt trong môi trường thực tế vẫn là một thách thức lớn do sự đa dạng về góc chụp, điều kiện ánh sáng, chất lượng ảnh, độ tuổi, giới tính và sự khác biệt trong biểu cảm của từng người. Các phương pháp truyền thống dựa trên đặc trưng thủ công thường gặp nhiều hạn chế về độ chính xác và khả năng khái quát hóa.

Sự ra đời của các mô hình học sâu, đặc biệt là mạng nơ-ron tích chập (Convolutional Neural Network - CNN), đã mang lại hiệu quả vượt trội trong các bài toán phân loại ảnh. Trong đó, kiến trúc ResNet50 nổi bật nhờ khả năng học các đặc trưng sâu, khắc phục hiện tượng mất mát gradient và đạt hiệu suất cao trên nhiều bộ dữ liệu lớn. Bên cạnh đó, bộ dữ liệu RAF-DB (Real-world Affective Faces Database) cung cấp tập ảnh khuôn mặt đa dạng, phản ánh tốt các tình huống thực tế, giúp nâng cao khả năng huấn luyện và đánh giá mô hình nhận diện cảm xúc.

Xuất phát từ những lý do trên, đề tài "**Xây dựng hệ thống nhận diện cảm xúc khuôn mặt sử dụng mạng ResNet50 và bộ dữ liệu RAF-DB**" được thực hiện nhằm nghiên cứu, xây dựng và đánh giá một hệ thống nhận diện cảm xúc tự động có độ chính xác cao. Kết quả của đề tài không chỉ góp phần củng cố kiến thức về học sâu và thị giác máy tính mà còn tạo nền tảng cho việc phát triển các ứng dụng thông minh trong tương lai.

1.2. Mục đích nghiên cứu.

Đề tài được thực hiện nhằm nghiên cứu và xây dựng một hệ thống nhận diện cảm xúc khuôn mặt tự động dựa trên các kỹ thuật học sâu (Deep Learning), sử dụng mô hình ResNet50 kết hợp với bộ dữ liệu RAF-DB để phân loại các trạng thái cảm xúc cơ bản của con người.

Cụ thể, đề tài hướng đến các mục đích sau:

- Nghiên cứu cơ sở lý thuyết về nhận diện cảm xúc khuôn mặt, mạng nơ-ron tích chập (CNN) và các phương pháp học sâu trong bài toán phân loại ảnh.
- Tìm hiểu cấu trúc và đặc điểm của bộ dữ liệu RAF-DB, đồng thời thực hiện các bước tiền xử lý và tăng cường dữ liệu nhằm nâng cao chất lượng huấn luyện mô hình.
- Xây dựng mô hình nhận diện cảm xúc dựa trên kiến trúc ResNet50 được huấn luyện trước (Pretrained Model) để khai thác hiệu quả các đặc trưng khuôn mặt.
- Huấn luyện và đánh giá mô hình trên các tập dữ liệu huấn luyện, kiểm tra và đánh giá nhằm xác định khả năng nhận diện cảm xúc của hệ thống.
- Xây dựng giao diện ứng dụng bằng Streamlit cho phép người dùng thực hiện các chức năng như huấn luyện mô hình, đánh giá kết quả và dự đoán cảm xúc từ ảnh đầu vào.
- Phân tích kết quả thực nghiệm, đánh giá ưu điểm và hạn chế của hệ thống, từ đó đề xuất các hướng cải tiến và phát triển trong tương lai.

Thông qua việc thực hiện đề tài, nhóm mong muốn vận dụng và củng cố các kiến thức đã học về Trí tuệ nhân tạo, Học máy, Học sâu và Thị giác máy tính; đồng thời xây dựng một hệ thống có khả năng ứng dụng trong các lĩnh vực như giáo dục thông minh, chăm sóc khách hàng, giám sát hành vi và tương tác người – máy.

1.3. Đối tượng và phạm vi nghiên cứu.

1.3.1. Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài là các phương pháp nhận diện cảm xúc khuôn mặt dựa trên kỹ thuật Học sâu (Deep Learning), đặc biệt là việc ứng dụng mạng nơ-ron tích chập (Convolutional Neural Network - CNN) trong bài toán phân loại cảm xúc từ ảnh khuôn mặt.

Đề tài tập trung nghiên cứu:

- Các trạng thái cảm xúc cơ bản của con người được biểu diễn thông qua khuôn mặt.
- Kiến trúc mạng ResNet50 và khả năng ứng dụng trong bài toán phân loại ảnh.
- Các kỹ thuật tiền xử lý dữ liệu và tăng cường dữ liệu (Data Augmentation).
- Các phương pháp huấn luyện và đánh giá mô hình học sâu.

- Việc xây dựng hệ thống nhận diện cảm xúc và giao diện tương tác với người dùng.

Các cảm xúc được nhận diện trong hệ thống gồm 7 lớp:

- Surprise (Ngạc nhiên)
- Fear (Sợ hãi)
- Disgust (Ghê tởm)
- Happiness (Vui vẻ)
- Sadness (Buồn bã)
- Anger (Tức giận)
- Neutral (Bình thường)

1.3.2. Phạm vi nghiên cứu

Do giới hạn về thời gian, dữ liệu và tài nguyên tính toán, đề tài được thực hiện trong phạm vi sau:

Về dữ liệu

Sử dụng bộ dữ liệu RAF-DB (Real-world Affective Faces Database).

- Dữ liệu đầu vào là ảnh khuôn mặt tĩnh đã được gán nhãn cảm xúc.
- Không nghiên cứu trên dữ liệu video hoặc dữ liệu cảm xúc đa phương thức (âm thanh, văn bản,...).

Về mô hình

- Sử dụng kiến trúc ResNet50 được huấn luyện trước trên ImageNet.
- Áp dụng kỹ thuật Transfer Learning để tăng hiệu quả huấn luyện.
- Sử dụng hàm mất mát Cross Entropy Loss và thuật toán tối ưu SGD. □
Không nghiên cứu các mô hình khác như Vision Transformer (ViT), EfficientNet hay ConvNeXt.

Về chức năng hệ thống

Hệ thống được xây dựng với các chức năng chính:

- Huấn luyện mô hình nhận diện cảm xúc.
- Lưu và tải mô hình đã huấn luyện.
- Đánh giá mô hình trên tập dữ liệu kiểm thử.

- Dự đoán cảm xúc từ ảnh đầu vào.
- Hiển thị kết quả thông qua giao diện Streamlit.

Về môi trường thực nghiệm

- Ngôn ngữ lập trình: Python.
- Thư viện chính: PyTorch, Torchvision, Streamlit, NumPy, Matplotlib. □
Thiết bị huấn luyện: GPU NVIDIA (CUDA) hoặc CPU khi cần thiết.

1.4. Phương pháp tiếp cận và Định hướng giải pháp

1.4.1. Phương pháp tiếp cận

Để giải quyết bài toán nhận diện cảm xúc khuôn mặt, đề tài tiếp cận theo hướng ứng dụng các kỹ thuật Học sâu (Deep Learning) trong lĩnh vực Thị giác máy tính. Thay vì sử dụng các phương pháp trích xuất đặc trưng thủ công truyền thống, hệ thống sử dụng mạng nơ-ron tích chập (Convolutional Neural Network - CNN) để tự động học các đặc trưng quan trọng từ dữ liệu ảnh khuôn mặt.


Quá trình thực hiện được tiến hành theo các bước sau:

- Nghiên cứu cơ sở lý thuyết về nhận diện cảm xúc khuôn mặt, học sâu và các mô hình CNN hiện đại.
- Thu thập và tìm hiểu bộ dữ liệu RAF-DB, phân tích cấu trúc dữ liệu và các nhãn cảm xúc.
- Tiền xử lý dữ liệu, chuẩn hóa kích thước ảnh và áp dụng các kỹ thuật tăng cường dữ liệu (Data Augmentation) nhằm nâng cao khả năng tổng quát hóa của mô hình.
- Sử dụng mô hình ResNet50 đã được huấn luyện trước trên bộ dữ liệu ImageNet để thực hiện Transfer Learning.
- Huấn luyện mô hình trên tập dữ liệu huấn luyện và đánh giá hiệu năng trên tập kiểm tra.
- Xây dựng giao diện người dùng bằng Streamlit để hỗ trợ quá trình huấn luyện, kiểm thử và dự đoán cảm xúc.
- Phân tích kết quả thực nghiệm thông qua các chỉ số đánh giá như Accuracy, Precision, Recall, F1-Score và Confusion Matrix.

Phương pháp tiếp cận này giúp tận dụng sức mạnh của các mô hình học sâu hiện đại, đồng thời giảm thời gian huấn luyện nhờ sử dụng các trọng số đã được học trước.

1.4.2. Định hướng giải pháp

Đề tài lựa chọn giải pháp xây dựng hệ thống nhận diện cảm xúc khuôn mặt dựa trên mô hình ResNet50 kết hợp với bộ dữ liệu RAF-DB. Kiến trúc hệ thống được thiết kế theo quy trình sau:



Trong đó:

- **Bộ dữ liệu RAF-DB** được sử dụng làm nguồn dữ liệu huấn luyện và đánh giá mô hình.
- **ResNet50** đóng vai trò là mạng trích xuất đặc trưng chính, có khả năng học các đặc trưng khuôn mặt ở nhiều mức độ khác nhau.
- **Transfer Learning** được áp dụng nhằm tận dụng các đặc trưng đã học từ bộ dữ liệu ImageNet, giúp mô hình hội tụ nhanh và đạt độ chính xác cao hơn.

- **Data Augmentation** được sử dụng để tạo thêm các biến thể dữ liệu thông qua xoay ảnh, lật ảnh, thay đổi độ sáng và dịch chuyển ảnh.
- **Dropout** và **L2 Regularization** được sử dụng nhằm giảm hiện tượng quá khớp (Overfitting).
- **Hàm mất mát Cross Entropy Loss** và thuật toán tối ưu **SGD (Stochastic Gradient Descent)** được sử dụng trong quá trình huấn luyện.

Bên cạnh mô hình nhận diện, đề tài còn xây dựng một ứng dụng Web sử dụng Streamlit nhằm cung cấp giao diện trực quan cho người dùng. Hệ thống cho phép thực hiện các chức năng như huấn luyện mô hình, đánh giá kết quả trên tập dữ liệu kiểm thử và dự đoán cảm xúc từ ảnh đầu vào.

Giải pháp được lựa chọn hướng tới mục tiêu đạt được độ chính xác cao, dễ triển khai, dễ mở rộng và có khả năng ứng dụng trong các hệ thống tương tác người – máy, giáo dục thông minh và phân tích hành vi người dùng trong thực tế.

1.5 .Ý nghĩa khoa học của đề tài

1.5.1. Ý nghĩa khoa học

Đề tài góp phần nghiên cứu và ứng dụng các phương pháp Học sâu (Deep Learning) trong lĩnh vực Thị giác máy tính, đặc biệt là bài toán nhận diện cảm xúc khuôn mặt. Thông qua việc sử dụng mô hình ResNet50 kết hợp với kỹ thuật Transfer Learning, đề tài giúp làm rõ khả năng áp dụng các mạng nơ-ron tích chập hiện đại vào bài toán phân loại cảm xúc từ ảnh khuôn mặt.

Bên cạnh đó, đề tài còn cung cấp cơ sở thực nghiệm về quy trình xây dựng một hệ thống nhận diện cảm xúc hoàn chỉnh, bao gồm các bước tiền xử lý dữ liệu, tăng cường dữ liệu, huấn luyện mô hình, đánh giá kết quả và triển khai ứng dụng. Kết quả nghiên cứu có thể được sử dụng làm tài liệu tham khảo cho các nghiên cứu tiếp theo liên quan đến nhận diện cảm xúc, phân tích hành vi người dùng và tương tác người – máy.

Ngoài ra, quá trình thực hiện đề tài giúp kiểm chứng hiệu quả của việc sử dụng mô hình ResNet50 được huấn luyện trước trên bộ dữ liệu ImageNet đối với bộ dữ liệu RAF-DB, từ đó đánh giá khả năng học và trích xuất đặc trưng khuôn mặt trong môi trường thực tế.

1.5.2. Ý nghĩa thực tiễn

Về mặt thực tiễn, hệ thống nhận diện cảm xúc được xây dựng trong đề tài có khả năng tự động phân tích và xác định trạng thái cảm xúc của con người thông qua ảnh khuôn mặt, góp phần giảm sự phụ thuộc vào việc đánh giá chủ quan của con người.

Ngoài ra, hệ thống được xây dựng bằng ngôn ngữ Python và triển khai trên nền tảng Streamlit nên có khả năng mở rộng và phát triển thành các ứng dụng thực tế trong tương lai. Đây cũng là cơ sở để tiếp tục nghiên cứu các mô hình tiên tiến hơn nhằm nâng cao độ chính xác và khả năng nhận diện cảm xúc trong các điều kiện phức tạp hơn

Kết quả của đề tài có thể được ứng dụng trong nhiều lĩnh vực khác nhau như:

- **Giáo dục thông minh:** hỗ trợ đánh giá mức độ tập trung, hứng thú hoặc trạng thái cảm xúc của người học trong quá trình học tập trực tuyến
- **Chăm sóc khách hàng:** phân tích cảm xúc khách hàng để nâng cao chất lượng dịch vụ và trải nghiệm người dùng.
- **Tương tác người – máy:** giúp các hệ thống thông minh, trợ lý ảo hoặc robot giao tiếp phản hồi phù hợp với trạng thái cảm xúc của người dùng.
- **Y tế và hỗ trợ tâm lý:** hỗ trợ theo dõi và đánh giá trạng thái cảm xúc của bệnh nhân trong quá trình điều trị hoặc tư vấn tâm lý.
- **Giám sát hành vi và an ninh:** hỗ trợ phát hiện các trạng thái cảm xúc bất thường phục vụ công tác quản lý và giám sát.

Ngoài ra, hệ thống được xây dựng bằng ngôn ngữ Python và triển khai trên nền tảng Streamlit nên có khả năng mở rộng và phát triển thành các ứng dụng thực tế trong tương lai. Đây cũng là cơ sở để tiếp tục nghiên cứu các mô hình tiên tiến hơn nhằm nâng cao độ chính xác và khả năng nhận diện cảm xúc trong các điều kiện phức tạp hơn

1.6 Bố cục báo cáo của bài tập lớn

CHƯƠNG 2 : CƠ SỞ LÝ THUYẾT VÀ CÔNG NGHỆ LIÊN QUAN

2.1 Tổng quan về nhận diện cảm xúc khuôn mặt

Nhận diện cảm xúc khuôn mặt (Facial Expression Recognition - FER) là một bài toán thuộc lĩnh vực Thị giác máy tính (Computer Vision) và Trí tuệ nhân tạo (Artificial Intelligence), nhằm xác định trạng thái cảm xúc của con người thông qua hình ảnh hoặc video khuôn mặt. Đây là một trong những hướng nghiên cứu quan trọng bởi cảm xúc đóng vai trò thiết yếu trong giao tiếp và tương tác giữa con người với nhau cũng như giữa con người với máy tính.

Theo các nghiên cứu tâm lý học, phần lớn thông tin cảm xúc trong giao tiếp được truyền tải thông qua biểu cảm khuôn mặt. Vì vậy, việc xây dựng các hệ thống có khả năng tự động nhận diện cảm xúc giúp máy tính hiểu được trạng thái tâm lý của người dùng, từ đó nâng cao hiệu quả tương tác và hỗ trợ ra quyết định trong nhiều lĩnh vực khác nhau.

Một hệ thống nhận diện cảm xúc khuôn mặt thường bao gồm các bước chính: □ Thu thập dữ liệu khuôn mặt □ Tiền xử lý dữ liệu.

- Trích xuất đặc trưng.
- Phân loại cảm xúc.
- Đánh giá kết quả.

Trong những năm gần đây, các phương pháp học sâu đã chứng minh được hiệu quả vượt trội so với các phương pháp truyền thống nhờ khả năng tự động học đặc trưng từ dữ liệu mà không cần thiết kế thủ công .

2.2 . Các trạng thái cảm xúc cơ bản.

Năm 1971, nhà tâm lý học Paul Ekman đã đề xuất sáu cảm xúc cơ bản có tính phổ quát ở con người, bao gồm:

- Happiness (Vui vẻ)
- Sadness (Buồn bã)
- Anger (Tức giận)
- Fear (Sợ hãi)
- Disgust (Ghê tởm)
- Surprise (Ngạc nhiên)

Sau này, nhiều bộ dữ liệu nhận diện cảm xúc bổ sung thêm trạng thái Neutral (Bình thường), tạo thành bảy lớp cảm xúc phổ biến được sử dụng trong các bài toán nhận diện cảm xúc hiện nay.

2.3. Học máy, học sâu.

2.3.1 Tổng quan về trí tuệ nhân tạo

Trí tuệ Nhân tạo (Artificial Intelligence - AI) là một lĩnh vực rộng lớn của khoa học máy tính, tập trung vào việc tạo ra các hệ thống máy tính có khả năng thực hiện các tác vụ mà thông thường đòi hỏi trí thông minh của con người. Các tác vụ này bao gồm học hỏi, suy luận, giải quyết vấn đề, nhận thức, hiểu ngôn ngữ tự nhiên, và ra quyết định. Mục tiêu của AI không chỉ là mô phỏng trí tuệ con người mà còn là tạo ra các hệ thống thông minh có thể hỗ trợ hoặc thay thế con người trong nhiều hoạt động phức tạp.

2.3.2 Học máy (Machine Learning)

Học máy (Machine Learning - ML) là một nhánh quan trọng của AI, tập trung vào việc phát triển các thuật toán và mô hình cho phép máy tính "học" từ dữ liệu mà không cần được lập trình một cách tường minh cho từng tác vụ cụ thể. Thay vì viết ra các quy tắc cố định, các mô hình ML tự động tìm ra các mẫu (patterns) và mối quan hệ tiềm ẩn trong dữ liệu để đưa ra dự đoán hoặc quyết định về dữ liệu mới.

Có ba loại học máy chính :

Học có giám sát (Supervised learning) Trong học có giám sát, mô hình được huấn luyện trên một tập dữ liệu đã được gán nhãn (labeled data), nghĩa là mỗi điểm dữ liệu đầu vào đều có một đầu ra (nhãn) tương ứng đã biết trước. Mục tiêu của mô hình là học một hàm ánh xạ từ đầu vào đến đầu ra sao cho có thể dự đoán chính xác nhãn cho các dữ liệu đầu vào mới chưa từng thấy.

- **Bài toán phân loại (Classification)** : Dự đoán một nhãn rời rạc (categorical label) . Ví dụ : phân loại email là spam hay không spam , nhận dạng chữ viết tay , hoặc trong đề tài này là dự đoán cảm xúc con người . Mô hình sẽ học cách phân biệt các lớp dựa trên đặc trưng của dữ liệu đầu vào.
- **Bài toán Hồi quy (Regression)** : Dự đoán một giá trị liên tục (continuous value) . Ví dụ : dự báo nhiệt độ ngày mai , dự đoán giá nhà dựa trên diện tích và vị trí .


Học không giám sát (Unsupervised learning) Trong học không giám sát, mô hình được huấn luyện trên dữ liệu không được gán nhãn. Mục tiêu là tự khám phá ra cấu trúc hoặc các mẫu tiềm ẩn trong dữ liệu.

- Phân cụm (Clustering) : Nhóm các điểm dữ liệu tương tự nhau vào cùng một cụm . Ví dụ : phân nhóm khách hàng dựa trên hành vi mua sắm.
- Giảm chiều dữ liệu (Dimensionality reduction) giảm số lượng biến đầu vào (đặc trưng) mà vẫn giữ được các thông tin quan trọng , giúp đơn giản hóa mô hình và giảm nhiễu . Ví dụ : phân tích thành phần chính (PCA) .
- Luật kết hợp (Association rule learning) Tìm ra các quy tắc mô tả mối quan hệ giữa các mục trong tập dữ liệu lớn . Ví dụ : “ người ta hay ăn kem vào mùa hè”

Học tăng cường (Reinforcement Learning) Trong học tăng cường, một "tác nhân" (agent) học cách hành động trong một "môi trường" (environment) để tối đa hóa một "phần thưởng" (reward) tích lũy theo thời gian. Tác nhân học thông qua thử và sai, nhận phản hồi dưới dạng phần thưởng hoặc hình phạt cho mỗi hành động. Ví dụ: huấn luyện robot tự đi, huấn luyện chương trình chơi game.

2.3.3. Học sâu (Deep Learning)

Học sâu (Deep Learning) là một lĩnh vực con của Học máy, dựa trên các Mạng Nơ-ron Nhân tạo (Artificial Neural Networks - ANNs) có nhiều lớp (deep architectures). "Deep" ở đây ám chỉ số lượng lớn các lớp xử lý thông tin trong mạng, cho phép mô hình học các biểu diễn dữ liệu (data representations) ở nhiều mức độ trừu tượng khác nhau. Các lớp đầu thường học các đặc trưng đơn giản (ví dụ: cạnh, góc trong ảnh), trong khi các lớp sâu hơn kết hợp các đặc trưng này để học các khái niệm phức tạp hơn (ví dụ: bộ phận của đối tượng, toàn bộ đối tượng).



Sự phát triển mạnh mẽ của Học sâu trong thập kỷ qua được thúc đẩy bởi ba yếu tố chính:

- **Sự sẵn có của dữ liệu lớn (Big Data):** Các mô hình Học sâu thường đòi hỏi một lượng lớn dữ liệu để huấn luyện hiệu quả.
- **Sự phát triển của phần cứng tính toán mạnh mẽ:** Đặc biệt là các Bộ xử lý Đồ họa (GPUs) cho phép thực hiện các phép toán ma trận song song với tốc độ cao, cần thiết cho việc huấn luyện các mạng nơ-ron lớn.
- **Những cải tiến về thuật toán:** Bao gồm các kiến trúc mạng mới, hàm kích hoạt hiệu quả hơn, kỹ thuật điều chuẩn tốt hơn và các thuật toán tối ưu tiên tiến.

Ưu điểm của học sâu:

- Tự động học đặc trưng từ dữ liệu.
- Khả năng xử lý dữ liệu lớn.
- Hiệu quả cao trong các bài toán hình ảnh và thị giác máy tính.
- Giảm sự phụ thuộc vào việc thiết kế đặc trưng thủ công

Các kiến trúc học sâu phổ biến ngoài mạng Nơ-ron tích chập CNN ra:

Máy biến áp (Transformers): Ban đầu được phát triển cho dịch máy, kiến trúc Transformer dựa trên cơ chế "chú ý" (attention mechanism) đã cách mạng hóa lĩnh vực xử lý ngôn ngữ tự nhiên và cũng đang được ứng dụng thành công trong thị giác máy tính.

Mạng Nơ-ron Hồi quy (Recurrent Neural Networks - RNNs): Phù hợp cho dữ liệu dạng chuỗi (sequential data) như văn bản, giọng nói, chuỗi thời gian. RNN có khả năng ghi nhớ thông tin từ các bước thời gian trước đó. Các biến thể phổ biến bao gồm LSTM (Long Short-Term Memory) và GRU (Gated Recurrent Unit).

Mạng Sinh Đối nghịch (Generative Adversarial Networks - GANs): Bao gồm hai mạng (một mạng sinh và một mạng phân biệt) cạnh tranh với nhau, có khả năng tạo ra dữ liệu mới rất thực tế (ví dụ: ảnh, video).


Trong lĩnh vực nhận diện cảm xúc khuôn mặt, học sâu cho phép mô hình tự động học các đặc điểm như hình dạng mắt, miệng, lông mày và các chuyển động cơ mặt để xác định trạng thái cảm xúc.

2.4 Mạng nơ-ron nhân tạo (neural networks)

Mạng nơ-ron nhân tạo (Neural Network - NN) là một mô hình lập trình rất đẹp lấy cảm hứng từ mạng nơ-ron thần kinh. Kết hợp với các kỹ thuật học sâu (Deep Learning - DL), NN đang trở thành một công cụ rất mạnh mẽ mang lại hiệu quả tốt nhất cho nhiều bài toán khó như nhận dạng ảnh, giọng nói hay xử lý ngôn ngữ tự nhiên. Một mạng Neural Networks sẽ có 3 kiểu tầng:

- Tầng vào (input layer): Là tầng bên trái cùng của mạng thể hiện cho các đầu vào của mạng

- Tầng ra (output layer): Là tầng bên phải cùng của mạng thể hiện cho các đầu ra của mạng.
- Tầng ẩn (hidden layer): Là tầng nằm giữa tầng vào và tầng ra thể hiện cho việc suy luận logic của mạng. Lưu ý rằng, một NN chỉ có 1 tầng vào và 1 tầng ra nhưng có thể có nhiều tầng ẩn.



2.5 Mạng nơ-ron tích chập (CNN)

Mạng Nơ-ron Tích chập (CNN hoặc ConvNet) là một lớp đặc biệt của mạng nơ-ron nhân tạo, được thiết kế đặc biệt hiệu quả cho việc xử lý dữ liệu có cấu trúc dạng lưới, chẳng hạn như hình ảnh. CNN đã trở thành kiến trúc thống trị trong các bài toán thị giác máy tính.


2.5.1 Kiến trúc điển hình của một mạng CNN

Một mạng CNN điển hình thường bao gồm một chuỗi các khối xử lý, mỗi khối thường chứa:

- **Một hoặc nhiều Lớp Tích chập (Convolutional Layers):** Để trích xuất các đặc trưng từ ảnh đầu vào
- **Một Hàm Kích hoạt (Activation Function) (ví dụ: ReLU):** Để đưa tính phi tuyến vào mô hình.
- **Một Lớp Gộp (Pooling Layer) (ví dụ: Max Pooling):** Để giảm kích thước không gian của các bản đồ đặc trưng và làm cho biểu diễn đặc trưng trở nên mạnh mẽ hơn đối với các biến đổi nhỏ.

Sau một vài khối tích chập và gộp, các bản đồ đặc trưng có độ trừu tượng cao thu được thường được duỗi phẳng (flattened) thành một vector một chiều. Vector

này sau đó được đưa vào một hoặc nhiều Lớp Kết nối Đầy đủ (Fully Connected Layers) để thực hiện nhiệm vụ phân loại cuối cùng. Lớp Dropout thường được chèn vào giữa các lớp để giảm overfitting.



2.5.2 Các thành phần cốt lõi của CNN

2.5.2.1 Lớp tích chập

Lớp Tích chập (Convolutional Layer) : Đây là lớp nền tảng của CNN, thực hiện phép toán tích chập giữa đầu vào và một tập hợp các bộ lọc (kernels).

Phép toán tích chập và vai trò của bộ lọc (kernel/filter) : Một bộ lọc là một ma trận nhỏ các trọng số. Phép tích chập được thực hiện bằng cách trượt bộ lọc này qua toàn bộ ảnh đầu vào (hoặc bản đồ đặc trưng từ lớp trước). Tại mỗi vị trí, tích từng phần tử (element-wise product) giữa bộ lọc và vùng ảnh tương ứng được tính toán, sau đó các giá trị này được cộng lại để tạo ra một giá trị duy nhất trong bản đồ đặc trưng đầu ra. Vai trò của bộ lọc là phát hiện các mẫu (patterns) cụ thể trong ảnh. Ví dụ, một bộ lọc có thể được huấn luyện để phát hiện các cạnh ngang, một bộ lọc khác phát hiện các cạnh dọc, hoặc các họa tiết phức tạp hơn. Các lớp tích chập đầu tiên thường học các đặc trưng cấp thấp (như cạnh, góc, màu sắc), trong khi các lớp sâu hơn học cách kết hợp các đặc trưng này để nhận diện các cấu trúc phức tạp hơn (như bộ phận của biển báo, hình dạng tổng thể của biển báo).

Bản đồ đặc trưng (Feature Map) : Mỗi bộ lọc khi trượt qua ảnh đầu vào sẽ tạo ra một bản đồ đặc trưng (feature map) hai chiều. Bản đồ này làm nổi bật các vùng trong ảnh đầu vào mà bộ lọc đó "nhận ra" (có phản hồi mạnh). Nếu một lớp tích

chập có K bộ lọc, nó sẽ tạo ra K bản đồ đặc trưng. Độ sâu (depth) của đầu ra của lớp tích chập chính là số lượng bộ lọc.

Tham số: Kích thước bộ lọc, số lượng bộ lọc, stride, padding :

- **Kích thước bộ lọc (Filter/Kernel Size):** Xác định kích thước của vùng cục bộ mà bộ lọc xem xét (ví dụ: 3x3, 5x5). Kích thước nhỏ hơn (ví dụ 3x3) thường được ưa chuộng trong các mạng hiện đại.
- **Số lượng bộ lọc (Number of Filters):** Xác định độ sâu của bản đồ đặc trưng đầu ra. Đây là một siêu tham số quan trọng, thể hiện "khả năng" (capacity) của lớp trong việc học các đặc trưng.
- **Stride (Bước trượt):** Xác định số pixel mà bộ lọc dịch chuyển qua ảnh sau mỗi phép tính. Stride bằng 1 có nghĩa là bộ lọc di chuyển từng pixel một. Stride lớn hơn 1 sẽ làm giảm kích thước của bản đồ đặc trưng đầu ra. (Trong Keras, stride mặc định là (1,1)).
- **Padding (Đệm):** Để kiểm soát kích thước của bản đồ đặc trưng đầu ra và đảm bảo bộ lọc có thể xử lý các pixel ở rìa ảnh một cách hiệu quả. Có hai loại padding phổ biến: Valid padding (mặc định trong Keras): Không sử dụng đệm. Kích thước đầu ra sẽ nhỏ hơn đầu vào và Same padding: Thêm đệm (thường là các pixel 0) xung quanh ảnh đầu vào sao cho kích thước không gian (chiều cao, chiều rộng) của bản đồ đặc trưng đầu ra bằng với kích thước đầu vào (khi stride=1).

Chia sẻ trọng số (Weight Sharing) :

- Đây là một đặc điểm quan trọng của CNN. Cùng một bộ lọc (tức là cùng một bộ trọng số) được sử dụng để quét qua toàn bộ ảnh. Điều này có hai lợi ích lớn
- Giảm đáng kể số lượng tham số: So với một lớp kết nối đầy đủ, số lượng tham số trong lớp tích chập nhỏ hơn rất nhiều, giúp mô hình dễ huấn luyện hơn và ít bị overfitting hơn
- Bất biến với vị trí (Translation Invariance): Nếu một mẫu (ví dụ: một cạnh thẳng đứng) xuất hiện ở một vị trí trong ảnh, bộ lọc tương ứng sẽ kích hoạt. Nếu cùng mẫu đó xuất hiện ở vị trí khác, cùng bộ lọc đó vẫn sẽ kích hoạt. Điều này có nghĩa là mạng có thể nhận diện một đặc trưng bất kể nó xuất hiện ở đâu trong ảnh.


2.5.2.2 .Hàm kích hoạt (Activation Function)

Sau mỗi phép toán tích chập (hoặc phép toán trong lớp Dense), một hàm kích hoạt thường được áp dụng cho từng phần tử của kết quả.

Vai trò của tính phi tuyến : Nếu không có hàm kích hoạt phi tuyến, một mạng nơ-ron dù có bao nhiêu lớp cũng chỉ tương đương với một mô hình tuyến tính đơn lớp. Các hàm kích hoạt phi tuyến cho phép mạng học các mối quan hệ phức tạp và phi tuyến trong dữ liệu, điều này cực kỳ quan trọng đối với các bài toán thực tế như nhận dạng ảnh.

Hàm ReLU (Rectified Linear Unit - activation='relu') và các biến thể :

- **Hàm ReLU** được định nghĩa là $f(x)=\max(0,x)$. Nó trả về x nếu x dương, và trả về 0 nếu x âm. □ **Tính toán đơn giản:** Nhanh hơn so với các hàm kích hoạt phức tạp như sigmoid hay tanh.
- **Giảm vấn đề triệt tiêu gradient (Vanishing Gradient Problem):** Đối với các giá trị đầu vào dương, đạo hàm của ReLU là 1, giúp gradient lan truyền tốt hơn qua nhiều lớp, cho phép huấn luyện các mạng sâu hiệu quả hơn.
- **Tạo ra các biểu diễn thưa (Sparse Representations):** Vì ReLU "tắt" các nơ-ron có giá trị đầu vào âm, nó có thể dẫn đến các biểu diễn đặc trưng thưa, đôi khi có lợi.
- **Nhược điểm** là nếu một nơ-ron ReLU nhận đầu vào luôn âm trong quá trình huấn luyện, nó sẽ luôn có output là 0 và gradient đi qua nó cũng là 0. Nơ-ron này sẽ ngừng học. Các biến thể của ReLU như Leaky ReLU, Parametric ReLU (PReLU), Exponential Linear Unit (ELU) được đề xuất để giải quyết vấn đề "ReLU chết"



2.5.2.3. Lớp Gộp (Pooling Layer - MaxPooling2D)


Lớp gộp thường được chèn vào giữa các lớp tích chập liên tiếp trong một CNN.

Mục đích :

- **Giảm chiều không gian (Downsampling):** Lớp gộp làm giảm kích thước chiều cao và chiều rộng của các bản đồ đặc trưng, từ đó giảm số lượng tham số tính toán ở các lớp sau và giúp kiểm soát overfitting.
- **Tạo ra sự bất biến với các dịch chuyển nhỏ (Local Translation Invariance):** Bằng cách lấy giá trị lớn nhất (Max Pooling) hoặc trung bình (Average Pooling) trong một vùng cục bộ, lớp gộp làm cho biểu diễn đặc trưng trở nên ít nhạy cảm hơn với vị trí chính xác của đặc trưng đó trong vùng. Ví dụ, nếu một đặc trưng dịch chuyển một chút trong cửa sổ pooling, output của pooling layer vẫn có thể không đổi (đối với Max Pooling). **Max Pooling và Average Pooling :**
- **Max Pooling:** Chọn giá trị lớn nhất từ các nơ-ron trong một cửa sổ (receptive field) của bản đồ đặc trưng trước đó. Đây là loại pooling phổ biến


nhất và được sử dụng trong myModel() với pool_size=(2,2). Nó có xu hướng giữ lại các đặc trưng nổi bật nhất

- **Average Pooling:** Tính giá trị trung bình của các nơ-ron trong cửa sổ. Lớp pooling thường được áp dụng độc lập cho từng kênh (depth slice) của bản đồ đặc trưng đầu vào.



2.5.2.4 Lớp Duỗi Phẳng (Flatten Layer - Flatten)


Sau một chuỗi các lớp tích chập và lớp gộp, các bản đồ đặc trưng thu được thường có dạng tensor 3D (chiều cao x chiều rộng x số kênh). Để đưa dữ liệu này vào các lớp kết nối đầy đủ (Dense layers) truyền thống (vốn yêu cầu đầu vào là vector 1D), lớp Flatten được sử dụng. Nó đơn giản là "duỗi thẳng" tensor 3D thành một vector 1D duy nhất bằng cách nối các hàng (hoặc cột) lại với nhau. Ví dụ, nếu output của lớp pooling cuối cùng là $5 \times 5 \times 4$ thì lớp Flatten sẽ trở thành một vector có $5 \times 5 \times 4 = 100$ phần tử.



2.5.2.5 Lớp kết nối đầy đủ (Fully Connected layer)

Các lớp kết nối đầy đủ (còn gọi là lớp Dense) thường được đặt ở cuối kiến trúc CNN, sau khi các đặc trưng đã được trích xuất và duỗi phẳng. Trong lớp Dense, mỗi nơ-ron được kết nối với tất cả các nơ-ron (hoặc activations) ở lớp trước đó.

- Vai trò: Các lớp Dense thực hiện nhiệm vụ phân loại cấp cao dựa trên các đặc trưng đã được học từ các lớp tích chập. Chúng kết hợp các đặc trưng này để đưa ra quyết định cuối cùng.
- Lớp Output: Lớp Dense cuối cùng là lớp output, có số nơ-ron bằng với số lượng lớp cần phân loại (noOfClasses). Hàm kích hoạt cho lớp output thường là softmax cho bài toán phân loại đa lớp. Hàm softmax chuyển đổi vector điểm số thô từ lớp Dense thành một phân phối xác suất trên các lớp, trong đó mỗi giá trị biểu thị xác suất đầu vào thuộc về lớp tương ứng, và tổng các xác suất này bằng 1.




2.5.2.6 . Lớp dropout và kỹ thuật điều khiển (Regularization)

Overfitting (quá khớp) là một vấn đề phổ biến trong Học máy, xảy ra khi mô hình học quá tốt trên dữ liệu huấn luyện (đạt độ chính xác cao) nhưng lại hoạt động kém trên dữ liệu mới chưa từng thấy (độ chính xác thấp trên tập xác thực/kiểm tra). Điều này có nghĩa là mô hình đã học cả nhiễu và các chi tiết không quan trọng trong tập huấn luyện, thay vì học các quy luật tổng quát. Dropout là một kỹ thuật điều chỉnh mạnh mẽ và đơn giản để giảm overfitting trong mạng nơ-ron.

Cách hoạt động: Trong mỗi bước huấn luyện, Dropout ngẫu nhiên "bỏ qua" (tạm thời vô hiệu hóa, đặt output về 0) một tỷ lệ nơ-ron nhất định trong một lớp, cùng với tất cả các kết nối đến và đi của chúng. Các nơ-ron bị bỏ qua được chọn ngẫu nhiên ở mỗi bước huấn luyện (hoặc mỗi batch). Lợi ích:

- **Ngăn chặn sự đồng thích nghi (co-adaptation) của các nơ-ron:** Buộc các nơ-ron phải học các đặc trưng hữu ích một cách độc lập hơn, thay vì dựa dẫm vào một vài nơ-ron cụ thể.
- **Tạo ra nhiều "mạng con" (sub-networks):** Có thể coi Dropout như việc huấn luyện một tập hợp lớn các mạng nơ-ron con khác nhau (mỗi mạng con có một tập hợp nơ-ron khác nhau bị bỏ qua). Khi dự đoán, hiệu ứng tương tự như lấy trung bình dự đoán của các mạng con này. Dropout thường được áp dụng cho các lớp kết nối đầy đủ, nhưng cũng có thể dùng cho các lớp tích chập. Nó chỉ được kích hoạt trong quá trình huấn luyện và bị tắt đi trong quá trình đánh giá/dự đoán (lúc này, các trọng số thường được nhân với tỷ lệ giữ lại ($1 - \text{dropout_rate}$) để bù đắp).



2.6 Kiến trúc ResNet50


2.6.1. Giới thiệu ResNet

ResNet (Residual Network) được giới thiệu đến công chúng vào năm 2015 và thậm chí đã giành được vị trí thứ 1 trong cuộc thi ILSVRC 2015 với tỉ lệ lỗi top 5 chỉ 3.57%. Không những thế nó còn đứng vị trí đầu tiên trong cuộc thi ILSVRC and COCO 2015 với ImageNet Detection, ImageNet localization, Coco detection và Coco segmentation. Hiện tại thì có rất nhiều biến thể của kiến trúc ResNet với số lớp khác nhau như ResNet-18, ResNet-34, ResNet-50, ResNet-101, ResNet-152,... Với tên là ResNet theo sau là một số chỉ kiến trúc ResNet với số lớp nhất định.

2.6.2 Tại sao lại xuất hiện mạng ResNet

Mạng ResNet (R) là một mạng CNN được thiết kế để làm việc với hàng trăm lớp. Một vấn đề xảy ra khi xây dựng mạng CNN với nhiều lớp chập sẽ xảy ra hiện tượng *Vanishing Gradient* dẫn tới quá trình học tập không tốt.

Trước hết thì Backpropagation Algorithm là một kỹ thuật thường được sử dụng trong quá trình training. Ý tưởng chung của thuật toán là sẽ đi từ output layer đến input layer và tính toán gradient của cost function tương ứng cho từng parameter (weight) của mạng. Gradient Descent sau đó được sử dụng để cập nhật các parameter đó.




Toàn bộ quá trình trên sẽ được lặp đi lặp lại cho tới khi mà các parameter của network được hội tụ. Thông thường chúng ta sẽ có một hyperparameter (số Epoch - số lần mà traninig set được duyệt qua một lần và weights được cập nhật) định nghĩa cho số lượng vòng lặp để thực hiện quá trình này. Nếu số lượng vòng lặp quá nhỏ thì ta gặp phải trường hợp mạng có thể sẽ không cho ra kết quả tốt và ngược lại thời gian tranining sẽ lâu nếu số lượng vòng lặp quá lớn.



Tuy nhiên, trong thực tế Gradients thường sẽ có giá trị nhỏ dần khi đi xuống các layer thấp hơn. Dẫn đến kết quả là các cập nhật thực hiện bởi Gradients Descent không làm thay đổi nhiều weights của các layer đó và làm chúng không thể hội tụ và mạng sẽ không thu được kết quả tốt. Hiện tượng như vậy gọi là **Vanishing Gradients**. Đây là lí do mà resnet được ra đời.

2.6.3 Kiến trúc mạng Resnet

Cho nên giải pháp mà ResNet đưa ra là sử dụng kết nối "tắt" đồng nhất để xuyên qua một hay nhiều lớp. Một khối như vậy được gọi là một Residual Block, như trong hình sau :



ResNet gần như tương tự với các mạng gồm có convolution, activation, pooling và fully-connected layer. Ảnh bên trên hiển thị khối dư được sử dụng trong mạng. Xuất hiện một mũi tên cong xuất phát từ đầu và kết thúc tại cuối khối dư. Hay nói cách khác là sẽ bổ sung Input X vào đầu ra của layer, hay chính là phép cộng mà ta thấy trong hình minh họa, việc này sẽ chống lại việc đạo hàm bằng 0, do vẫn còn cộng thêm X. Với $H(x)$ là giá trị dự đoán, $F(x)$ là giá trị thật (nhãn), chúng ta muốn $H(x)$ bằng hoặc xấp xỉ $F(x)$. Việc $F(x)$ có được từ x như sau:


$X \rightarrow \text{weight1} \rightarrow \text{ReLU} \rightarrow \text{weight2}$

Giá trị $H(x)$ có được bằng cách:

$F(x) + x \rightarrow \text{ReLU}$

Trong đó, Resnet50 là một biến thể của kiến trúc Resnet gồm 50 lớp có tham số học được.

2.6.4 Xây dựng resnet50



"ID BLOCK" trong hình trên là viết tắt của từ Identity block và ID BLOCK x3 nghĩa là có 3 khối Identity block chồng lên nhau. Nội dung hình trên như sau :

- Zero-padding : Input với (3,3) □ Stage 1 : Tích chập (Conv1) với 64 filters với shape(7,7), sử dụng stride (2,2).

BatchNorm, MaxPooling (3,3).

- Stage 2 : Convolutional block sử dụng 3 filter với size $64 \times 64 \times 256$, $f=3$, $s=1$. Có 2 Identity blocks với filter size $64 \times 64 \times 256$, $f=3$.
- Stage 3 : Convolutional sử dụng 3 filter size $128 \times 128 \times 512$, $f=3, s=2$. Có 3 Identity blocks với filter size $128 \times 128 \times 512$, $f=3$.
- Stage 4 : Convolutional sử dụng 3 filter size $256 \times 256 \times 1024$, $f=3, s=2$. Có 5 Identity blocks với filter size $256 \times 256 \times 1024$, $f=3$.
- Stage 5 : Convolutional sử dụng 3 filter size $512 \times 512 \times 2048$, $f=3, s=2$. Có 2 Identity blocks với filter size $512 \times 512 \times 2048$, $f=3$.
- The 2D Average Pooling : sử dụng với kích thước (2,2). □ The Flatten.
- Fully Connected (Dense) : sử dụng softmax activation.

2.7. Transfer Learning

Transfer Learning là kỹ thuật tận dụng tri thức đã được học từ một mô hình được huấn luyện trước trên tập dữ liệu lớn để giải quyết một bài toán mới. Thay vì khởi tạo toàn bộ trọng số ngẫu nhiên và huấn luyện từ đầu, mô hình sẽ kế thừa các đặc trưng đã học được từ tập dữ liệu nguồn, giúp quá trình học nhanh hơn và đạt độ chính xác cao hơn.

Trong đề tài này, mô hình ResNet50 được sử dụng với trọng số khởi tạo từ ImageNet. ImageNet là bộ dữ liệu lớn chứa hơn một triệu ảnh thuộc một nghìn lớp khác nhau. Trong quá trình huấn luyện trên ImageNet, ResNet50 đã học được nhiều đặc trưng quan trọng như cạnh, góc, đường nét, kết cấu và các mẫu hình ảnh phức tạp. Những đặc trưng này cũng có giá trị đối với bài toán nhận diện cảm xúc khuôn mặt.

Khi áp dụng Transfer Learning, phần lớn các lớp tích chập của ResNet50 được giữ nguyên kiến trúc và sử dụng các trọng số đã được học trước. Lớp phân loại cuối cùng của mô hình được thay thế bằng một lớp Fully Connected mới có đầu ra gồm 7 nút tương ứng với 7 cảm xúc trong bộ dữ liệu RAF-DB, bao gồm: Surprise, Fear, Disgust, Happiness, Sadness, Anger và Neutral.

2.8. Bộ dữ liệu RAF-DB

RAF-DB (Real-world Affective Faces Database) là bộ dữ liệu nhận diện cảm xúc được sử dụng phổ biến trong các nghiên cứu hiện nay.

Đặc điểm :

- Hơn 30.000 ảnh khuôn mặt thực tế.
- Dữ liệu được thu thập từ Internet.

- Nhiều góc nhìn và điều kiện ánh sáng khác nhau.
- Được gán nhãn thủ công bởi nhiều chuyên gia.

Các lớp cảm xúc được sử dụng trong đề tài:

- Surprise
- Fear
- Disgust
- Happiness
- Sadness
- Anger
- Neutral

RAF-DB phản ánh tốt các điều kiện thực tế nên phù hợp để đánh giá khả năng tổng quát hóa của mô hình.

2.9 Các kỹ thuật xử lý dữ liệu

Để nâng cao hiệu quả huấn luyện, đề tài áp dụng các kỹ thuật tăng cường dữ liệu gồm:

- Random Resized Crop.
- Random Horizontal Flip.
- Random Rotation.
- Color Jitter.
- Random Affine Transform. Các kỹ thuật này giúp:
- Tăng số lượng mẫu huấn luyện.
- Giảm hiện tượng overfitting.
- Nâng cao khả năng tổng quát hóa của mô hình.

2.10 Các chỉ số đánh giá mô hình

Để đánh giá hiệu quả của hệ thống, đề tài sử dụng các chỉ số:

2.10.1 Accuracy

Tỷ lệ dự đoán đúng trên tổng số mẫu: $\text{Accuracy} = (\text{Số mẫu dự đoán đúng} / \text{Tổng số mẫu}) \times 100\%$

2.10.2 Precision

Đánh giá mức độ chính xác của các dự đoán dương tính.

$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$ Trong số tất cả các mẫu được dự đoán là thuộc một lớp cụ thể, có bao nhiêu mẫu thực sự thuộc lớp đó? Precision cao cho thấy mô hình ít mắc lỗi False Positive.

2.10.3 Recall Đánh giá khả năng phát hiện đúng các mẫu thuộc lớp cần nhận diện.

$\text{Recall} = \frac{TP}{TP + FN}$ Trong số tất cả các mẫu thực sự thuộc một lớp cụ thể, mô hình đã nhận diện đúng được bao nhiêu mẫu? Recall cao cho thấy mô hình ít mắc lỗi False Negative.

2.10.4 F1-Score Là trung bình điều hòa giữa Precision và Recall.

$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$ Là trung bình điều hòa (harmonic mean) của Precision và Recall. F1-score hữu ích khi muốn cân bằng cả Precision và Recall, đặc biệt khi dữ liệu mất cân bằng.

2.10.5 Confusion Matrix

Ma trận nhầm lẫn thể hiện số lượng mẫu được phân loại đúng hoặc nhầm giữa các lớp cảm xúc khác nhau.

2.11 Công nghệ sử dụng trong đề tài

Các công nghệ chính được sử dụng gồm:

□ Python.

- PyTorch.
- Torchvision.
- NumPy.
- Matplotlib. □ Streamlit. Trong đó:
 - PyTorch được sử dụng để xây dựng và huấn luyện mô hình học sâu.
 - Torchvision hỗ trợ xử lý dữ liệu ảnh và cung cấp mô hình ResNet50.
 - Streamlit được sử dụng để xây dựng giao diện người dùng trực quan.
 - Matplotlib hỗ trợ trực quan hóa kết quả huấn luyện và đánh giá mô hình.

CHƯƠNG 3. PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG NHẬN DIỆN CẢM XÚC CON NGƯỜI

3.1. Quy trình tổng quan của hệ thống

Hệ thống nhận diện cảm xúc khuôn mặt được xây dựng nhằm tự động phân loại trạng thái cảm xúc của con người thông qua ảnh khuôn mặt đầu vào. Quá trình xây dựng hệ thống được thực hiện theo một chuỗi các bước từ thu thập dữ liệu, tiền xử lý, huấn luyện mô hình học sâu đến triển khai ứng dụng dự đoán. Mỗi giai đoạn đều đóng vai trò quan trọng trong việc đảm bảo độ chính xác và khả năng hoạt động ổn định của hệ thống.

Đầu tiên, bộ dữ liệu RAF-DB được sử dụng làm nguồn dữ liệu chính cho quá trình nghiên cứu và huấn luyện mô hình. Đây là bộ dữ liệu nhận diện cảm xúc khuôn mặt được sử dụng rộng rãi trong lĩnh vực thị giác máy tính, bao gồm các hình ảnh khuôn mặt được gán nhãn theo bảy trạng thái cảm xúc cơ bản gồm Surprise, Fear, Disgust, Happiness, Sadness, Anger và Neutral. Dữ liệu được tổ chức thành các tập huấn luyện và kiểm tra nhằm phục vụ cho việc xây dựng và đánh giá mô hình.

Sau khi thu thập dữ liệu, các ảnh đầu vào được đưa qua giai đoạn tiền xử lý. Mục đích của bước này là chuẩn hóa dữ liệu và đưa toàn bộ ảnh về cùng một định dạng phù hợp với kiến trúc mạng nơ-ron được sử dụng. Các thao tác bao gồm thay đổi kích thước ảnh về 224×224 pixel, chuyển đổi ảnh sang dạng tensor và chuẩn hóa giá trị điểm ảnh bằng các tham số trung bình và độ lệch chuẩn đã được tính toán trước trên bộ dữ liệu RAF-DB. Việc chuẩn hóa giúp giảm sự khác biệt về phân bố dữ liệu giữa các ảnh và hỗ trợ quá trình huấn luyện đạt hiệu quả tốt hơn.

Tiếp theo, hệ thống thực hiện tăng cường dữ liệu (Data Augmentation) trên tập huấn luyện nhằm gia tăng tính đa dạng của dữ liệu. Các kỹ thuật như xoay ảnh ngẫu nhiên, lật ảnh theo chiều ngang, thay đổi độ sáng, độ tương phản, cắt ảnh ngẫu nhiên và dịch chuyển vị trí ảnh được áp dụng để mô phỏng các điều kiện thực tế khác nhau. Nhờ đó mô hình có khả năng học được nhiều đặc trưng hơn, đồng thời giảm hiện tượng quá khớp (Overfitting) khi huấn luyện trên tập dữ liệu có kích thước giới hạn.

Sau giai đoạn chuẩn bị dữ liệu, mô hình ResNet50 được sử dụng làm kiến trúc chính cho hệ thống nhận diện cảm xúc. Đây là một mạng tích chập sâu đã được huấn luyện trước trên tập dữ liệu ImageNet với hàng triệu ảnh thuộc nhiều lớp khác nhau. Thay vì huấn luyện toàn bộ mô hình từ đầu, nghiên cứu áp dụng kỹ thuật Transfer Learning bằng cách kế thừa các trọng số đã học trước và thay thế lớp phân loại cuối cùng để phù hợp với bài toán nhận diện bảy loại cảm xúc. Phương pháp này giúp rút ngắn thời gian huấn luyện, giảm yêu cầu về tài nguyên tính toán và nâng cao độ chính xác của mô hình.

Trong quá trình huấn luyện, mô hình sử dụng hàm mất mát Cross Entropy Loss để đánh giá mức độ sai lệch giữa kết quả dự đoán và nhãn thực tế. Bộ tối ưu SGD (Stochastic Gradient Descent) kết hợp với hệ số Momentum được sử dụng để cập nhật trọng số mạng nơ-ron. Đồng thời, kỹ thuật Dropout được áp dụng tại lớp phân loại cuối nhằm hạn chế hiện tượng quá khớp và tăng khả năng tổng quát hóa của mô hình trên dữ liệu mới.

Sau mỗi vòng lặp huấn luyện (epoch), hệ thống tiến hành đánh giá mô hình trên tập dữ liệu xác thực. Các chỉ số như Loss và Accuracy được ghi nhận để theo dõi quá trình học của mô hình. Khi mô hình đạt được độ chính xác cao hơn so với các lần huấn luyện trước, trọng số tương ứng sẽ được lưu lại dưới dạng mô hình tốt nhất (Best Model). Việc lưu trữ checkpoint cũng cho phép tiếp tục quá trình huấn luyện từ các trạng thái đã lưu khi cần thiết.

Khi quá trình huấn luyện hoàn tất, mô hình được đánh giá trên tập kiểm tra độc lập nhằm xác định hiệu năng thực tế. Các chỉ số đánh giá bao gồm độ chính xác tổng thể, độ chính xác theo từng lớp cảm xúc, ma trận nhầm lẫn (Confusion Matrix), Precision, Recall và F1-Score. Những chỉ số này giúp đánh giá khả năng nhận diện cảm xúc của mô hình cũng như xác định các lớp cảm xúc dễ bị nhầm lẫn.

Cuối cùng, mô hình được tích hợp vào ứng dụng giao diện người dùng được phát triển bằng Streamlit. Hệ thống cho phép người dùng tải lên ảnh khuôn mặt, thực hiện dự đoán cảm xúc theo thời gian thực và hiển thị kết quả dưới dạng nhãn cảm xúc cùng xác suất dự đoán tương ứng. Ngoài ra, ứng dụng còn hỗ trợ các chức năng huấn luyện mô hình, đánh giá mô hình trên tập dữ liệu kiểm tra và hiển thị các chỉ số thống kê trực quan, tạo điều kiện thuận lợi cho việc nghiên cứu và khai thác hệ thống trong thực tế.

Toàn bộ quy trình trên tạo thành một hệ thống nhận diện cảm xúc hoàn chỉnh, từ khâu xử lý dữ liệu đầu vào cho đến dự đoán kết quả đầu ra. Việc kết hợp bộ dữ liệu RAF-DB, mô hình ResNet50 và kỹ thuật Transfer Learning đã góp phần nâng cao hiệu quả nhận diện cảm xúc, đồng thời đảm bảo khả năng ứng dụng của hệ thống trong nhiều bài toán thực tế liên quan đến tương tác người – máy và phân tích hành vi con người.

3.2. Phân tích và chuẩn bị dữ liệu RAF-DB

3.2.1. Giới thiệu bộ dữ liệu RAF-DB Trong nghiên cứu này, bộ dữ liệu RAF-DB (Real-world Affective Faces

Database) được sử dụng làm nguồn dữ liệu chính để huấn luyện và đánh giá mô hình nhận diện cảm xúc khuôn mặt. RAF-DB là một trong những bộ dữ liệu phổ biến trong lĩnh vực nhận diện cảm xúc, được xây dựng từ các hình ảnh khuôn mặt thu thập từ Internet trong nhiều điều kiện khác nhau như thay đổi góc nhìn, ánh sáng, độ tuổi và giới tính.

Mỗi ảnh trong bộ dữ liệu được gán nhãn theo bảy trạng thái cảm xúc cơ bản của con người bao gồm: Surprise (ngạc nhiên), Fear (sợ hãi), Disgust (ghê tởm), Happiness (vui vẻ), Sadness (buồn bã), Anger (tức giận) và Neutral (trung tính). Việc sử dụng bộ dữ liệu này giúp mô hình có khả năng học được các đặc trưng cảm xúc đa dạng và gần với điều kiện thực tế.

3.2.2. Cấu trúc dữ liệu

Dữ liệu được tổ chức thành hai tập chính gồm tập huấn luyện (Training Set) và tập kiểm tra (Testing Set). Mỗi lớp cảm xúc được lưu trữ trong một thư mục riêng biệt, tương ứng với nhãn cảm xúc của ảnh.

Trong quá trình huấn luyện, tập dữ liệu huấn luyện tiếp tục được chia thành hai phần gồm tập Train và tập Validation. Tập Validation được sử dụng để theo dõi khả năng học của mô hình và phát hiện hiện tượng quá khớp trong quá trình huấn luyện.

3.2.3. Chia tập dữ liệu

Để đảm bảo tính khách quan trong đánh giá mô hình, dữ liệu được chia theo tỷ lệ 80% cho huấn luyện và 20% cho xác thực. Quá trình chia dữ liệu được thực hiện ngẫu

nhiên nhưng cố định bằng Seed nhằm đảm bảo khả năng tái lập kết quả giữa các lần thực nghiệm.

Việc tách riêng tập Validation giúp theo dõi quá trình hội tụ của mô hình và lựa chọn được phiên bản mô hình có hiệu năng tốt nhất trên dữ liệu chưa từng xuất hiện trong quá trình học.

3.3. Tiền xử lý dữ liệu ảnh

3.3.1. Thay đổi kích thước ảnh Các hình ảnh trong bộ dữ liệu RAF-DB có kích thước không đồng nhất. Để phù hợp với kiến trúc ResNet50, toàn bộ ảnh đầu vào được thay đổi về kích thước 224×224 pixel.

Việc chuẩn hóa kích thước giúp dữ liệu đầu vào có cùng số chiều, đồng thời đảm bảo tương thích với mô hình đã được huấn luyện trước trên bộ dữ liệu ImageNet.

3.3.2. Chuyển đổi ảnh sang Tensor

Sau khi thay đổi kích thước, ảnh được chuyển đổi từ định dạng RGB sang Tensor của PyTorch. Mỗi điểm ảnh được biểu diễn dưới dạng số thực trong khoảng từ 0 đến 1. Bước chuyển đổi này cho phép dữ liệu được xử lý trực tiếp bởi các phép toán ma trận trong mạng nơ-ron sâu.

3.3.3. Chuẩn hóa dữ liệu

Để tăng tốc độ hội tụ và ổn định quá trình huấn luyện, các ảnh đầu vào được chuẩn hóa dựa trên giá trị trung bình và độ lệch chuẩn được tính toán từ bộ dữ liệu RAF-DB.

Quá trình chuẩn hóa giúp giảm sự khác biệt về phân bố dữ liệu giữa các ảnh, từ đó làm cho thuật toán tối ưu hoạt động hiệu quả hơn. Đồng thời, việc chuẩn hóa còn giúp hạn chế ảnh hưởng của điều kiện ánh sáng và màu sắc khác nhau giữa các ảnh trong bộ dữ liệu.

3.4. Tăng cường dữ liệu (Data Augmentation)

3.4.1. Mục đích tăng cường dữ liệu

Trong các bài toán học sâu, số lượng dữ liệu thường ảnh hưởng lớn đến khả năng học của mô hình. Để tăng tính đa dạng của dữ liệu huấn luyện mà không cần thu thập thêm ảnh mới, kỹ thuật Data Augmentation được áp dụng.

Việc tăng cường dữ liệu giúp mô hình học được nhiều biến thể khác nhau của khuôn mặt, từ đó nâng cao khả năng tổng quát hóa và giảm hiện tượng Overfitting.

3.4.2. Các kỹ thuật tăng cường dữ liệu được sử dụng

Hệ thống áp dụng nhiều kỹ thuật tăng cường dữ liệu khác nhau ;

- Thứ nhất là Random Resized Crop, cho phép cắt ngẫu nhiên một vùng của ảnh và thay đổi kích thước về 224×224 pixel. Kỹ thuật này giúp mô hình tập trung vào các vùng khác nhau trên khuôn mặt.
- Thứ hai là Random Horizontal Flip với xác suất 50%, giúp mô hình học được các đặc trưng khuôn mặt theo cả hai hướng trái và phải.
- Thứ ba là Random Rotation, thực hiện xoay ảnh ngẫu nhiên trong khoảng ± 15 độ nhằm mô phỏng sự thay đổi góc nghiêng của đầu trong thực tế.
- Ngoài ra, Color Jitter được sử dụng để điều chỉnh độ sáng, độ tương phản và độ bão hòa màu sắc của ảnh. Điều này giúp mô hình thích nghi tốt hơn với các điều kiện ánh sáng khác nhau.
- Cuối cùng, Random Affine được áp dụng để tạo ra các phép dịch chuyển nhỏ trên ảnh, mô phỏng sự thay đổi vị trí khuôn mặt trong khung hình.

Nhờ các kỹ thuật trên, tập dữ liệu huấn luyện trở nên phong phú hơn và góp phần nâng cao hiệu quả của mô hình.

3.5. Thiết kế kiến trúc mô hình ResNet50

3.5.1 Lựa chọn mô hình

Trong nghiên cứu này, ResNet50 được lựa chọn làm mô hình nhận diện cảm xúc khuôn mặt. Đây là một trong những kiến trúc mạng tích chập sâu nổi tiếng với khả năng học đặc trưng mạnh mẽ và hiệu quả trên nhiều bài toán thị giác máy tính.

So với các mạng CNN truyền thống, ResNet50 giải quyết được hiện tượng suy giảm độ chính xác khi tăng số lượng tầng mạng nhờ cơ chế kết nối tắt (Skip Connection).

3.5.2 Cấu trúc tổng thể của ResNet50

ResNet50 gồm 50 lớp học sâu được tổ chức thành nhiều khối Residual Block liên tiếp. Mỗi khối bao gồm các lớp tích chập (Convolution Layer), chuẩn hóa Batch Normalization và hàm kích hoạt ReLU.

Đầu vào của mô hình là ảnh RGB kích thước $224 \times 224 \times 3$. Sau khi đi qua các tầng tích chập và trích xuất đặc trưng, dữ liệu được đưa qua lớp Global Average Pooling trước khi đến lớp phân loại cuối cùng.

3.5.3. Residual Learning

Điểm nổi bật nhất của ResNet50 là cơ chế Residual Learning. Thay vì học trực tiếp ánh xạ đầu vào sang đầu ra, mô hình chỉ học phần sai khác giữa đầu vào và đầu ra mong muốn.

Nhờ đó, thông tin từ các lớp đầu có thể truyền trực tiếp tới các lớp sâu hơn thông qua đường kết nối tắt. Cơ chế này giúp hạn chế hiện tượng tiêu biến gradient và cho phép xây dựng các mạng nơ-ron rất sâu mà vẫn duy trì hiệu quả huấn luyện.

3.5.4. Thiết kế lớp phân loại cảm xúc

Mô hình ResNet50 gốc được huấn luyện trên bộ dữ liệu ImageNet với 1000 lớp đối tượng khác nhau. Để phù hợp với bài toán nhận diện cảm xúc, lớp Fully Connected cuối cùng được thay thế bằng một lớp mới gồm 7 nút đầu ra tương ứng với 7 trạng thái cảm xúc của bộ dữ liệu RAF-DB.

Bên cạnh đó, kỹ thuật Dropout với tỷ lệ 0.3 được bổ sung trước lớp phân loại nhằm giảm hiện tượng quá khớp và cải thiện khả năng tổng quát hóa của mô hình trên dữ liệu mới.

3.6. Transfer Learning

3.6.1. Khái niệm Transfer Learning

Transfer Learning là một kỹ thuật trong học sâu, trong đó một mô hình đã được huấn luyện trên một tập dữ liệu lớn sẽ được tái sử dụng cho một bài toán khác có liên quan. Thay vì huấn luyện mô hình từ đầu, phương pháp này tận dụng các đặc trưng đã học được từ dữ liệu trước đó, giúp giảm thời gian huấn luyện và cải thiện hiệu quả của mô hình, đặc biệt khi dữ liệu huấn luyện của bài toán mới có kích thước hạn chế.

Trong các mô hình thị giác máy tính, Transfer Learning thường được áp dụng với các mạng CNN đã được huấn luyện trên tập dữ liệu ImageNet, nơi chứa hàng triệu hình ảnh thuộc hàng nghìn lớp đối tượng khác nhau.

3.6.2. Áp dụng Transfer Learning trong ResNet50

Trong hệ thống nhận diện cảm xúc khuôn mặt, mô hình ResNet50 được sử dụng làm mô hình nền (backbone). Mô hình này đã được huấn luyện trước trên tập dữ liệu ImageNet, do đó có khả năng trích xuất các đặc trưng hình ảnh mạnh mẽ như cạnh, góc, hình dạng và cấu trúc khuôn mặt.

Khi áp dụng Transfer Learning, các trọng số của ResNet50 được giữ nguyên ở các tầng tích chập ban đầu. Chỉ có lớp Fully Connected cuối cùng được thay thế bằng một lớp mới phù hợp với bài toán hiện tại, bao gồm 7 đầu ra tương ứng với 7 trạng thái cảm xúc trong bộ dữ liệu RAF-DB.

3.6.3. Lợi ích của Transfer Learning

Việc sử dụng Transfer Learning mang lại nhiều lợi ích quan trọng. Thứ nhất, nó giúp giảm đáng kể thời gian huấn luyện do không cần khởi tạo và học lại toàn bộ mô hình từ đầu. Thứ hai, mô hình có khả năng hội tụ nhanh hơn và đạt độ chính xác cao hơn ngay cả khi dữ liệu huấn luyện không quá lớn. Thứ ba, phương pháp này giúp cải thiện khả năng tổng quát hóa của mô hình trên dữ liệu thực tế.

3.7. Cấu hình huấn luyện mô hình

3.7.1. Hàm mất mát (Loss Function) Trong bài toán phân loại cảm xúc, hàm mất mát Cross Entropy Loss được sử dụng để đo lường sự khác biệt giữa phân phối xác suất dự đoán của mô hình và nhãn thực tế. Đây là hàm mất mát phổ biến trong các bài toán phân loại đa lớp, giúp mô hình tối ưu hóa khả năng dự đoán chính xác từng lớp cảm xúc.

$$L = - \sum_{k=1}^K y_k \log(p_k)$$

3.7.2. Thuật toán tối ưu

Hệ thống sử dụng thuật toán tối ưu Stochastic Gradient Descent (SGD) kết hợp với Momentum. Thuật toán này giúp cập nhật trọng số của mô hình theo hướng

giảm dần hàm mất mát, đồng thời tăng tốc độ hội tụ và giảm dao động trong quá trình huấn luyện.

Bên cạnh đó, Weight Decay được sử dụng như một kỹ thuật regularization nhằm hạn chế hiện tượng overfitting bằng cách phạt các trọng số lớn trong mô hình.

3.7.3. Điều chỉnh tốc độ học (Learning Rate Scheduling)

Trong quá trình huấn luyện, tốc độ học được điều chỉnh theo chiến lược giảm dần theo từng giai đoạn. Cụ thể, sau một số epoch nhất định, learning rate sẽ được giảm xuống theo một hệ số cố định nhằm giúp mô hình hội tụ ổn định hơn trong các giai đoạn cuối của quá trình huấn luyện

3.7.4. Dropout và Regularization

Để hạn chế hiện tượng overfitting, kỹ thuật Dropout được áp dụng tại lớp Fully Connected cuối cùng của mô hình với tỷ lệ 0.3. Kỹ thuật này giúp ngẫu nhiên loại bỏ một số neuron trong quá trình huấn luyện, buộc mô hình phải học các đặc trưng tổng quát hơn thay vì phụ thuộc vào một số đặc trưng cụ thể.

Kỹ thuật regularization (chính quy hóa) được sử dụng để ngăn chặn hiện tượng quá khớp (overfitting). Nó hoạt động bằng cách bổ sung các ràng buộc hoặc phạt độ phức tạp của mô hình, giúp AI không ghi nhớ dữ liệu huấn luyện mà tập trung học các quy luật cốt lõi

$$Loss_{new} = Loss_{old} + \lambda \sum_{i=1}^n w_i^2$$

3.7.5. Các siêu tham số huấn luyện

Các siêu tham số quan trọng trong quá trình huấn luyện bao gồm số epoch, kích thước batch size, tốc độ học ban đầu, hệ số momentum và weight decay. Những tham số này được lựa chọn dựa trên thực nghiệm nhằm đạt được sự cân bằng giữa tốc độ huấn luyện và độ chính xác của mô hình.

3.8. Lưu trữ và tải mô hình

3.8.1. Cơ chế lưu checkpoint

Trong quá trình huấn luyện, mô hình được lưu lại dưới dạng checkpoint để tránh mất dữ liệu khi quá trình huấn luyện bị gián đoạn. Mỗi checkpoint bao gồm các thông tin quan trọng như trọng số của mô hình, trạng thái của optimizer, số epoch hiện tại và giá trị độ chính xác tốt nhất đạt được.

3.8.2. Lưu mô hình tốt nhất

Bên cạnh việc lưu checkpoint theo từng giai đoạn, hệ thống còn lưu lại mô hình có hiệu năng tốt nhất dựa trên độ chính xác của tập validation. Mô hình này được sử dụng cho mục đích dự đoán và đánh giá cuối cùng nhằm đảm bảo hiệu quả cao nhất.

3.8.3. Khôi phục quá trình huấn luyện

Cơ chế tải lại mô hình cho phép hệ thống tiếp tục quá trình huấn luyện từ trạng thái đã lưu trước đó. Điều này giúp tiết kiệm thời gian huấn luyện và đảm bảo tính liên tục trong quá trình nghiên cứu và thực nghiệm.

3.9. Thiết kế giao diện hệ thống (Streamlit Interface)

Hệ thống được xây dựng giao diện người dùng bằng thư viện Streamlit, cho phép tương tác trực tiếp với mô hình mà không cần sử dụng dòng lệnh. Giao diện được thiết kế theo hướng trực quan, chia thành nhiều tab chức năng bao gồm: Train, Test, Evaluate và Sample Test.

Ở phần **Training**, người dùng có thể tùy chỉnh các tham số như số epoch, batch size, learning rate và dropout. Giao diện hiển thị trạng thái huấn luyện theo thời gian thực, bao gồm loss, accuracy và tiến trình từng batch. Ngoài ra, hệ thống còn hiển thị biểu đồ quá trình học (training curve) giúp theo dõi sự hội tụ của mô hình.

Ở phần **Test**, người dùng có thể tải mô hình đã huấn luyện từ checkpoint và đánh giá trên tập test. Kết quả được hiển thị dưới dạng độ chính xác tổng thể và báo cáo chi tiết theo từng lớp.

Ở phần **Evaluate**, hệ thống cung cấp các công cụ phân tích nâng cao như confusion matrix và classification report, giúp đánh giá sâu hơn hiệu năng mô hình.

Cuối cùng, phần **Sample Test** cho phép người dùng tải lên một hình ảnh bất kỳ. Hệ thống sẽ thực hiện tiền xử lý ảnh, đưa qua mô hình ResNet50 đã huấn luyện và trả về kết quả dự đoán cảm xúc cùng với độ tin cậy tương ứng. Biểu đồ phân phối xác suất các lớp cảm xúc cũng được hiển thị để tăng tính trực quan.

Giao diện tổng thể được thiết kế đơn giản, dễ sử dụng nhưng vẫn đảm bảo đầy đủ chức năng của một hệ thống nhận diện cảm xúc dựa trên học sâu.

CHƯƠNG 4. KẾT QUẢ THỰC NGHIỆM VÀ ĐÁNH GIÁ

4.1. Môi trường thực nghiệm

4.1.1. Cấu hình phần cứng

Hệ thống thực nghiệm được triển khai trên máy có cấu hình:

□ CPU □

GPU: □

RAM:24G □

Ổ cứng:

4.1.2. Cấu hình phần mềm

Hệ thống được phát triển bằng ngôn ngữ Python và các thư viện chính:

- Python 3.11
- PyTorch
- torchvision □ NumPy
- scikit-learn
- Matplotlib
- Seaborn
- Streamlit (giao diện người dùng)

4.2. Dữ liệu thực nghiệm

Bộ dữ liệu RAF-DB được sử dụng trong nghiên cứu bao gồm 7 nhãn cảm xúc cơ bản:

- Surprise
- Fear
- Disgust
- Happiness
- Sadness
- Anger
- Neutral


Dữ liệu được chia thành 3 tập:

- Tập huấn luyện (Train set)
- Tập xác thực (Validation set)
- Tập kiểm thử (Test set)

4.3. Quá trình huấn luyện mô hình

Mô hình ResNet50 được sử dụng làm backbone chính cho bài toán phân loại cảm xúc. Trong quá trình huấn luyện:

- Hàm mất mát: CrossEntropyLoss
- Thuật toán tối ưu: SGD với momentum = 0.9
- Learning rate ban đầu: 0.01
- Batch size: 64 □ Số epoch: 100
- Regularization: Weight decay = $1e-4$,
- Dropout (tùy chọn)



The screenshot displays a training interface. On the left, a 'Configuration' panel shows training settings: Epochs (100), Batch Size (64), Learning Rate (0.010000), and checkboxes for Dropout and Paths. Below this, it shows 'Current Config: Model: resnet50'. The main area features a table with training metrics over 10 epochs. The table has three columns: Train Loss, Train Acc, and Val Acc. The metrics show a decreasing trend in loss and an increasing trend in accuracy over time.

Train Loss	Train Acc	Val Acc
0.0076	99.77%	83.94%
0.0063	99.82%	84.11%
0.0075	99.73%	83.86%
0.0055	99.86%	83.82%
0.0045	99.89%	84.19%
0.0036	99.90%	84.47%
0.0049	99.88%	84.64%

Epoch 46/100 | Batch 22/153 | Loss: 0.0040 | Acc: 100.00%

Trong quá trình huấn luyện, learning rate được điều chỉnh tự động dựa trên hiệu suất của mô hình trên tập validation nhằm giúp mô hình hội tụ tốt hơn.

4.4. Kết quả huấn luyện

Kết quả huấn luyện cho thấy mô hình ResNet50 đã học tốt các đặc trưng biểu cảm khuôn mặt trên bộ dữ liệu RAF-DB. Trong quá trình huấn luyện, giá trị hàm mất mát (Loss) giảm dần qua các epoch và đạt mức rất thấp ở giai đoạn cuối, chứng tỏ mô hình đã hội tụ ổn định. Đồng thời, độ chính xác trên tập huấn luyện đạt xấp xỉ 99,9%, cho thấy mô hình có khả năng phân loại rất tốt đối với các mẫu dữ liệu đã được sử dụng trong quá trình học.

Trên tập dữ liệu validation, mô hình đạt độ chính xác cao nhất khoảng 84,64%. Kết quả này cho thấy mô hình có khả năng tổng quát hóa tương đối tốt đối với các dữ liệu chưa xuất hiện trong quá trình huấn luyện. Độ chính xác validation duy trì ổn định quanh mức 84% trong nhiều epoch cuối, chứng tỏ quá trình học đã đạt trạng thái hội tụ và không còn cải thiện đáng kể khi tiếp tục tăng số epoch.

Train Loss	Train Acc	Val Acc
0.0049	99.88%	84.64%
Train Loss	Train Acc	Val Acc
0.0030	99.97%	84.39%

Tuy nhiên, có thể nhận thấy sự chênh lệch tương đối lớn giữa độ chính xác trên tập huấn luyện và tập validation. Điều này cho thấy mô hình xuất hiện hiện tượng overfitting ở một mức độ nhất định, tức là mô hình học rất tốt dữ liệu huấn luyện nhưng khả năng tổng quát hóa trên dữ liệu mới vẫn còn hạn chế. Mặc dù vậy, với việc áp dụng kỹ thuật tăng cường dữ liệu (Data Augmentation), Dropout và L2 Regularization thông qua Weight Decay, mức độ overfitting đã được kiểm soát tương đối hiệu quả.


Nhìn chung, kết quả thực nghiệm chứng minh rằng kiến trúc ResNet50 kết hợp với thuật toán tối ưu SGD có Momentum bằng 0,9 đã mang lại hiệu quả cao cho bài toán nhận dạng cảm xúc khuôn mặt. Độ chính xác đạt được đáp ứng yêu cầu của đề tài và là cơ sở để triển khai mô hình vào hệ thống nhận dạng cảm xúc thời gian thực.

4.5. Đánh giá trên tập kiểm thử

Sau khi hoàn thành quá trình huấn luyện, mô hình ResNet50 được đánh giá trên tập kiểm thử độc lập gồm 3.068 ảnh khuôn mặt. Kết quả cho thấy mô hình dự đoán chính xác 2.632 mẫu, đạt độ chính xác tổng thể 85,79%, tương ứng với tỷ lệ lỗi 14,21%.

Kết quả này cho thấy mô hình có khả năng nhận diện cảm xúc khuôn mặt khá tốt trên các dữ liệu chưa từng xuất hiện trong quá trình huấn luyện. Độ chính xác trên tập kiểm thử cao hơn 85% chứng minh rằng mô hình đã học được các đặc trưng biểu cảm quan trọng và có khả năng tổng quát hóa tương đối tốt.

Xét theo từng lớp cảm xúc, cảm xúc Hạnh phúc (Happiness) đạt độ chính xác cao nhất với 93,08%. Điều này cho thấy các đặc trưng của biểu cảm vui vẻ tương đối rõ ràng và dễ phân biệt với các nhóm cảm xúc khác. Các lớp Surprise, Neutral và Sadness cũng đạt kết quả tốt với độ chính xác lần lượt là 85,71%, 85,59% và 84,31%.



Trong khi đó, hai lớp Fear và Disgust có độ chính xác thấp nhất, lần lượt đạt 59,46% và 55,63%. Nguyên nhân có thể xuất phát từ sự tương đồng về đặc điểm

khuôn mặt giữa các cảm xúc tiêu cực, khiến mô hình dễ nhầm lẫn trong quá trình phân loại. Ngoài ra, sự mất cân bằng số lượng mẫu giữa các lớp trong bộ dữ liệu RAF-DB cũng có thể ảnh hưởng đến khả năng học của mô hình đối với các lớp này.

Nhìn chung, kết quả thực nghiệm cho thấy mô hình đã đạt hiệu quả tốt trong bài toán nhận diện cảm xúc khuôn mặt. Độ chính xác kiểm thử đạt 85,79% cho thấy mô hình đáp ứng được mục tiêu đề ra của đề tài và có tiềm năng ứng dụng trong các hệ thống nhận dạng cảm xúc thời gian thực.

CHƯƠNG 5. KẾT LUẬN VÀ ĐỀ XUẤT HƯỚNG PHÁT TRIỂN

5.1. Kết luận

Trong đề tài này, hệ thống nhận diện cảm xúc khuôn mặt đã được xây dựng và triển khai dựa trên mô hình học sâu ResNet50 kết hợp với bộ dữ liệu RAF-DB. Hệ thống thực hiện bài toán phân loại cảm xúc khuôn mặt thành 7 lớp cơ bản gồm: *Surprise, Fear, Disgust, Happiness, Sadness, Anger* và *Neutral*.

Trong quá trình thực hiện, đề tài đã đạt được một số kết quả chính như sau:

- Xây dựng thành công mô hình học sâu dựa trên kiến trúc ResNet50 với khả năng trích xuất đặc trưng mạnh mẽ từ ảnh khuôn mặt.
- Thiết kế và triển khai pipeline huấn luyện đầy đủ bao gồm tiền xử lý dữ liệu, tăng cường dữ liệu (data augmentation), huấn luyện, đánh giá và lưu mô hình.
- Áp dụng các kỹ thuật tối ưu hóa như SGD với momentum, giảm learning rate theo lịch trình và sử dụng dropout nhằm hạn chế overfitting.

- Xây dựng hệ thống đánh giá mô hình với các chỉ số như accuracy, loss, confusion matrix và classification report để phân tích hiệu quả mô hình.
- Phát triển giao diện ứng dụng trực quan bằng Streamlit, cho phép người dùng tải ảnh lên và dự đoán cảm xúc.

Kết quả thực nghiệm cho thấy mô hình có khả năng học được các đặc trưng quan trọng của khuôn mặt và đạt độ chính xác tương đối tốt trên tập dữ liệu kiểm thử. Tuy nhiên, hiệu suất giữa các lớp cảm xúc chưa đồng đều, đặc biệt đối với các lớp có số lượng mẫu ít hoặc đặc trưng dễ gây nhầm lẫn.

Nhìn chung, đề tài đã hoàn thành mục tiêu đặt ra ban đầu là xây dựng một hệ thống nhận diện cảm xúc khuôn mặt dựa trên học sâu, có khả năng hoạt động ổn định và có thể ứng dụng trong thực tế.

5.2. Hạn chế của hệ thống

Bên cạnh các kết quả đạt được, hệ thống vẫn còn tồn tại một số hạn chế như sau:

- Hiệu suất mô hình phụ thuộc nhiều vào chất lượng và sự cân bằng của dữ liệu RAF-DB.
- Mô hình ResNet50 tuy mạnh nhưng chưa được tối ưu sâu theo đặc thù bài toán cảm xúc (chưa sử dụng attention mechanism hoặc các kiến trúc chuyên biệt cho facial expression recognition).
- Quá trình huấn luyện còn tiêu tốn tài nguyên tính toán lớn và thời gian khá dài
- Hệ thống chưa được tối ưu để triển khai trên thiết bị nhẹ hoặc môi trường thời gian thực sự (edge devices).
- Giao diện Streamlit phục vụ demo, chưa phải là một hệ thống production hoàn chỉnh.

5.3. Đề xuất hướng phát triển

Trong tương lai, hệ thống có thể được cải tiến theo các hướng sau:

- **Cải thiện kiến trúc mô hình:** Áp dụng các kiến trúc tiên tiến hơn như EfficientNet, Vision Transformer (ViT), hoặc kết hợp Attention Mechanism (SE-block, CBAM) để tăng khả năng trích xuất đặc trưng.
- **Cải thiện hiệu năng huấn luyện:** Áp dụng các chiến lược như mixed precision training (FP16), early stopping và hyperparameter tuning tự động.
- **Triển khai thực tế:** Chuyển mô hình sang dạng lightweight (ONNX, TensorRT) để chạy trên thiết bị di động hoặc hệ thống nhúng.

- **Mở rộng ứng dụng:** Tích hợp hệ thống vào các bài toán thực tế như phân tích hành vi người dùng, hệ thống giám sát cảm xúc trong giáo dục, chăm sóc sức khỏe tinh thần hoặc hệ thống tương tác người–máy.
- **Nâng cấp hệ thống phần mềm:** Tách riêng backend inference và frontend, xây dựng API bằng FastAPI hoặc Flask để triển khai thành web service hoàn chỉnh.

Tài liệu tham khảo

- [1] He, K., Zhang, X., Ren, S., & Sun, J. (2016), Deep Residual Learning for Image Recognition, Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 770–778.
- [2] Li, S., & Deng, W. (2017), Reliable Crowdsourcing and Deep Locality-Preserving Learning for Expression Recognition in the Wild, Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 2852–2861.

- [3] Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012), ImageNet Classification with Deep Convolutional Neural Networks, Advances in Neural Information Processing Systems (NeurIPS), Vol. 25.
- [4] LeCun, Y., Bengio, Y., & Hinton, G. (2015), Deep Learning, Nature, Vol. 521, No. 7553, pp. 436–444.
- [5] Goodfellow, I., Bengio, Y., & Courville, A. (2016), Deep Learning, MIT Press, Cambridge, Massachusetts
- [6] Bottou, L. (2012), Stochastic Gradient Descent Tricks, Neural Networks: Tricks of the Trade, Springer, pp. 421–436.
- [7] Kingma, D. P., & Ba, J. (2015), Adam: A Method for Stochastic Optimization, International Conference on Learning Representations (ICLR).
- [8] Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., et al. (2019), PyTorch: An Imperative Style, High-Performance Deep Learning Library, Advances in Neural Information Processing Systems (NeurIPS), Vol. 32.
- [9] Deng, J., Dong, W., Socher, R., Li, L. J., Li, K., & Fei-Fei, L. (2009), *ImageNet: A Large-Scale Hierarchical Image Database*, Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 248–255.
- [10] Streamlit Documentation, Available at: <https://streamlit.io/>
- [11] kiến trúc resnet50 : <https://viblo.asia/p/gioi-thieu-mang-resnet-vyDZOa7R5wj>